

Architettura Cloud-Native per un Sistema di Retrieval Basato su Grafi Semantici

Sistemi Cloud

Santi Lisi · Dario Lazzara · Francesco Granata

Università degli Studi di Catania

Dipartimento di Matematica e Informatica

Sommario

Il presente elaborato descrive la progettazione e l'implementazione dell'infrastruttura cloud e di deployment a supporto di un sistema avanzato di retrieval semantico basato su grafi. Il progetto originale, sviluppato per l'esame di Deep Learning, esegue l'inferenza sfruttando un Vision-Language Model (VLM), Nomic e una Graph Neural Network (GCN). Data l'elevata complessità computazionale, è emersa la necessità di reingegnerizzare il sistema monolitico in una moderna architettura a microservizi asincroni. La relazione documenta il percorso evolutivo dell'infrastruttura, partendo da un ambiente containerizzato locale (Docker Compose), passando per un cluster Kubernetes locale (K3s) orchestrato tramite Ansible su macchine virtuali Multipass, fino a giungere a una soluzione Cloud-Native su Amazon Web Services (AWS) automatizzata tramite Terraform (Infrastructure as Code). L'architettura finale su AWS integra servizi completamente gestiti (S3, SQS, RDS, ElastiCache) per abbattere l'overhead operativo, dimostrando la scalabilità e la prontezza del sistema per un rilascio *enterprise*.

Parole chiave — cloud computing, microservizi, aws, terraform, k3s, ansible, docker, architettura distribuita

Indice

1	Introduzione	3
1.1	L'Obiettivo del Progetto: Dal Monolite al Cloud-Native	3
1.2	Analisi dei Requisiti Architettureali	4
1.3	Struttura della Trattazione	4
2	Applicativo, Pipeline AI e Ibridazione HPC	5
2.1	La Pipeline Asincrona	5
2.2	Ibridazione Cloud-HPC: Il Problema del Collo di Bottiglia	6
2.2.1	Sincronizzazione tramite Distributed Lock (Redis Semaforo)	6
3	Containerizzazione e Orchestrazione Locale	7
3.1	La Containerizzazione con Docker	7
3.2	Simulazione di una Topologia Multi-Nodo tramite Multipass	8
3.3	Automazione del Cluster con K3s e Ansible	8
4	Infrastruttura AWS e Servizi Gestiti	9
4.1	Infrastructure as Code con Terraform	9
4.2	Topologia di Rete e Sicurezza (VPC)	10
4.3	Offloading verso Servizi Gestiti AWS (PaaS/SaaS)	10
4.4	Risoluzione Criticità Hardware: Out-Of-Memory (OOM)	11
4.5	Innesco Serverless (Event-Driven) tramite AWS Lambda	11
5	Deployment su EKS ed Auto-Scaling Elastico	11
5.1	Gestione dei Secret e Manifesti Kubernetes	12
5.2	Event-Driven Auto-Scaling con KEDA	12
5.3	Continuous Integration e Continuous Deployment (CI/CD)	13
6	Conclusioni e Sviluppi Futuri	13
6.1	Sviluppi Futuri	14

1 Introduzione

Negli ultimi anni, la convergenza tra Computer Vision e Natural Language Processing ha portato alla creazione di modelli fondazionali di dimensioni sempre più imponenti, come i Vision-Language Models (VLM) e le Graph Neural Networks (GNN). Questi strumenti hanno rivoluzionato campi complessi come lo *Scene Understanding*, permettendo non solo di identificare oggetti isolati all'interno di un'immagine, ma di estrarne un vero e proprio "Grafo di Scena" (Scene Graph), catturando relazioni semantiche, spaziali e logiche.

Tuttavia, l'enorme potenza espressiva di queste architetture neurali, capaci di emulare processi cognitivi di alto livello, porta con sé un costo computazionale formidabile. L'elaborazione di una singola query visiva richiede il caricamento in memoria GPU (VRAM) di modelli con miliardi di parametri (come la famiglia Qwen-VL), seguiti da cicli di inferenza intrinsecamente sequenziali e lenti. A questo si aggiunge la necessità di mappare i grafi generati in spazi di embedding latenti (attraverso l'uso di GCN) e di interrogare massicci indici vettoriali (tramite librerie come FAISS) per effettuare ricerche per similarità semantica.

In un contesto di produzione o nell'implementazione di un motore di ricerca web-based, il tentativo di esporre queste funzionalità tramite architetture tradizionali monolitiche risulta rapidamente fallimentare. Una classica chiamata API REST sincrona, nella quale il server attende la fine dell'elaborazione AI prima di rispondere al client, si scontra inesorabilmente contro limiti fisici di rete e di risorse. I tempi di latenza necessari per l'inferenza di un VLM possono variare dai dieci secondi ad alcuni minuti, portando invariabilmente a *timeout* prematuri delle connessioni HTTP e alla saturazione dei web server, i cui *thread* rimarrebbero bloccati in uno stato di attesa attiva (*blocking I/O*).

1.1 L'Obiettivo del Progetto: Dal Monolite al Cloud-Native

Al fine di superare questo severo collo di bottiglia, l'obiettivo fondante di questo progetto di tesi è stato quello di reingegnerizzare in ottica *Cloud-Native* un'applicazione di elaborazione grafica e semantica inizialmente concepita per un'esecuzione locale e monolitica. Il sistema è stato destrutturato e riprogettato secondo i dettami delle architetture a microservizi distribuite e asincrone (*Event-Driven Architecture*), rendendolo intrinsecamente idoneo per il deployment su moderne infrastrutture Cloud elastiche di livello enterprise, come Amazon Web Services (AWS).

Questa migrazione architetturale non si è limitata a un semplice trasferimento dell'applicativo su server remoti (*lift-and-shift*), ma ha comportato una vera e propria riscrittura dei flussi logici. Si è optato per la separazione formale tra il *Gateway* web (incaricato esclusivamente di ricevere le richieste e servire l'interfaccia utente) e il motore di calcolo pesante, denominato *AI Worker*.

1.2 Analisi dei Requisiti Architettureali

La progettazione dell'architettura distribuita ha mirato a soddisfare specifici requisiti non funzionali e pattern ingegneristici del Cloud Computing:

- **Asincronia e Decoupling Estremo:** Si è reso indispensabile slegare completamente il ciclo di vita della richiesta HTTP dell'utente dall'elaborazione AI sottostante. Ciò è stato realizzato attraverso l'adozione di Message Broker (code di messaggistica) che agiscono da cuscinetto asincrono tra i microservizi.
- **Scalabilità Orizzontale Elastica:** Il traffico in ingresso, derivante da un ipotetico carico web di caricamento immagini, può essere fortemente imprevedibile (i cosiddetti *spike* di traffico). Lo strato di Worker che esegue le pipeline neurali deve avere la capacità di moltiplicarsi (effettuare *scale-out*) e contrarsi dinamicamente in proporzione diretta alla lunghezza della coda di messaggi in sospeso.
- **Isolamento e Containerizzazione Stateless:** Al fine di prevenire i classici conflitti tra dipendenze di sistema (driver CUDA, versioni di PyTorch, moduli web) e per garantire una riproducibilità bit-per-bit, l'intero applicativo è stato compartimentato in container Docker. I container sono stati progettati per essere rigorosamente *stateless*, affidando il mantenimento dello stato a database esterni.
- **Infrastructure as Code (IaC):** Ogni singola risorsa infrastrutturale (reti virtuali, bilanciatori di carico, istanze di calcolo e cluster Kubernetes) non è stata configurata manualmente tramite interfaccia grafica, per evitare errori umani o disallineamenti. Il deployment è stato codificato in script dichiarativi, rendendolo un processo deterministico e idempotente.

1.3 Struttura della Trattazione

La relazione dettagliata dell'architettura cloud sviluppata seguirà una struttura divisa per livelli di astrazione logica e implementativa:

1. **Applicativo, Pipeline AI e Ibridazione HPC (Capitolo 2):** Il secondo capitolo esplorerà il funzionamento interno della pipeline neurale, dalla ricezione dell'immagine fino all'inferenza del Grafo di Scena. Particolare enfasi verrà posta sulla natura ibrida della soluzione implementata: a causa dei limiti fisici del Cloud nel caricare on-demand il colossale modello Qwen-VL, il sistema è stato progettato per delegare, tramite script automatizzati, i task computazionalmente più onerosi verso un cluster HPC (*High Performance Computing*) universitario. Sarà descritta l'elegante soluzione architetturale del *Distributed Lock* usata per serializzare in modo sicuro l'accesso alle risorse limitate di tale cluster, mantenendo contemporaneamente parallelizzati tutti gli strati dell'applicativo sul Cloud.
2. **Orchestrazione Locale (Capitolo 3):** Prima di allocare risorse Cloud a pagamento, verrà documentata la fase di orchestrazione *on-premise*. Sarà mostrato come i servizi (tra cui PostgreSQL, Redis e RabbitMQ) siano stati virtualizzati sul computer locale

sfruttando Multipass e gestiti tramite una distribuzione leggera di Kubernetes (K3s), di cui l'installazione è stata automatizzata tramite Ansible.

3. **Infrastruttura AWS (Capitolo 4):** Il quarto capitolo segnerà il passaggio all'infrastruttura di Amazon Web Services (AWS). Verrà dissezionato il codice *Terraform* impiegato per forgiare una Virtual Private Cloud (VPC) estremamente sicura, segregata in subnet private e pubbliche, e per fare l'offloading dei datastore e dei message broker verso l'offerta PaaS nativa di AWS (RDS, SQS, ElastiCache e S3).
4. **Deployment ed Auto-Scaling Elastico (Capitolo 5):** L'ultimo capitolo analizzerà i manifesti di Kubernetes utilizzati per lanciare i microservizi all'interno dell'Elastic Kubernetes Service (EKS). Si focalizzerà sull'orchestrazione asincrona, sull'innescare *serverless* guidato da AWS Lambda e sull'implementazione vitale dell'Auto-Scaling elastico pilotato dagli eventi (Event-Driven) tramite KEDA.

Attraverso questa progressione, l'elaborato mira a dimostrare come la progettazione rigorosa e l'impiego dei giusti layer di astrazione cloud-native permettano di portare in produzione modelli di AI complessi e pesanti in modo scalabile e sicuro.

2 Applicativo, Pipeline AI e Ibridazione HPC

Il cuore logico e funzionale di questo progetto è rappresentato da un sofisticato motore di ricerca semantico visivo. L'intento dell'applicativo è consentire a un utente finale di caricare un'immagine dal proprio dispositivo e, attraverso una catena di elaborazione neurale, individuare le immagini concettualmente e strutturalmente più simili all'interno di un vasto database pre-calcolato.

A differenza delle tradizionali pipeline di *Image Retrieval* basate esclusivamente sull'estrazione di *feature* visive globali (es. architetture ResNet o ViT standard), questo sistema adotta un approccio avanzato incentrato sui **Grafi di Scena (Scene Graphs)**. Un grafo di scena modella l'immagine come un insieme di nodi (che rappresentano entità o oggetti) connessi da archi (che codificano le relazioni spaziali, semantiche o logiche tra di essi). Per generare tali grafi a partire da immagini non strutturate, il sistema si affida a potenti *Vision-Language Models* (VLM), nello specifico la famiglia Qwen-VL. Una volta ottenuto il grafo, quest'ultimo viene proiettato in uno spazio vettoriale continuo (embedding latente) tramite l'uso di una *Graph Convolutional Network* (GCN), nello specifico un'architettura GINE con Triple Margin Loss o varianti customizzate. L'embedding risultante viene infine confrontato con quelli memorizzati in un Vector Database ad alte prestazioni.

2.1 La Pipeline Asincrona

Per sostenere l'oneroso ciclo di calcolo descritto senza incorrere in timeout lato client, l'intera pipeline di elaborazione è stata progettata seguendo il paradigma architetturale dell'asincronia guidata dagli eventi (*Event-Driven*). Il flusso logico si articola nelle seguenti fasi:

1. **Upload e Intercettazione:** L'utente, tramite l'interfaccia React (Frontend), seleziona un'immagine. L'immagine non viene inviata al Backend tramite una tipica chiamata HTTP in base64 (che saturerebbe la banda e la memoria), ma viene caricata direttamente sullo storage a oggetti (S3 o una sua simulazione locale).
2. **Creazione del Job e Accodamento:** Il Backend (FastAPI) registra un nuovo "Job" assegnandogli un ID univoco in formato UUID, salvandone lo stato iniziale ("PENDING") sul database relazionale (PostgreSQL). Simultaneamente, il payload della richiesta (contenente il path dell'immagine e i metadati della ricerca) viene inserito in coda di messaggistica (RabbitMQ in locale, AWS SQS sul Cloud).
3. **Polling Asincrono:** A questo punto la chiamata HTTP del client si chiude con successo, restituendo immediatamente l'ID del Job. Il frontend attiva una routine di *polling* leggero (o WebSocket), interrogando il backend a intervalli regolari (es. ogni 1 secondo) esclusivamente per leggere lo stato del Job (es. "SCENE_GRAPH", "VECTOR_SEARCH", "COMPLETED") recuperandolo da un livello di cache ultraveloce (Redis), evitando di sovraccaricare il DB relazionale.
4. **Elaborazione del Worker:** Un componente separato, l'AI Worker, resta perennemente in ascolto sulla coda di messaggistica. Non appena percepisce la presenza di un messaggio, lo estrae (de-queue) e avvia la complessa pipeline neurale. Tutte le transizioni di stato della pipeline vengono istantaneamente riflesse su Redis, aggiornando in tempo reale la UI dell'utente.

2.2 Ibridazione Cloud-HPC: Il Problema del Collo di Bottiglia

Durante la migrazione verso l'infrastruttura Cloud-Native, è emerso un limite fisico ed economico intrinseco alle infrastrutture di Cloud Pubblico: il costo orario per il provisioning di nodi Kubernetes equipaggiati con GPU di fascia altissima (necessarie per far girare modelli VLM da svariati miliardi di parametri) è economicamente proibitivo in un contesto accademico.

Per ovviare a questo problema, si è optato per una soluzione di **Ibridazione Cloud-HPC**. L'infrastruttura Cloud (economica, elastica e basata su CPU) ospita l'intero strato web e di orchestrazione, mentre il calcolo intensivo (l'estrazione del Grafo di Scena tramite VLM) viene delegato asincronamente al cluster *High Performance Computing* (HPC) fornito dall'Università. Il Worker Cloud, tramite una connessione SSH automatizzata (utilizzando `paramiko`), trasferisce l'immagine, compila e sottomette uno script SLURM (`sbatch`) al cluster HPC, e attende passivamente il download dell'output testuale contenente il grafo.

2.2.1 Sincronizzazione tramite Distributed Lock (Redis Semaforo)

Tale architettura ibrida introduce tuttavia una complessa sfida nei sistemi distribuiti. Mentre l'Auto-Scaling del Cloud è in grado di spawnare decine di pod Worker in parallelo all'aumentare delle richieste (come verrà approfondito nel Capitolo 5), il cluster HPC a valle rappresenta un *collo di bottiglia rigido*: le risorse (GPU) assegnate al progetto sul cluster universitario permettono l'esecuzione di una sola istanza del modello VLM per volta. Se due pod Worker

Cloud tentassero simultaneamente di avviare il job SLURM sull'HPC, il secondo andrebbe in errore per esaurimento risorse (Out-of-Memory).

Per risolvere elegantemente questo collasso infrastrutturale garantendo contemporaneamente il massimo parallelismo, è stato implementato un **Distributed Lock** (Semaforo Distribuito) basato su Redis. La logica implementata nel Worker è la seguente:

- Prima di aprire la connessione SSH verso l'HPC, il Worker tenta di acquisire una chiave univoca in Redis (`SETNX lock:hpc_gpu`).
- Se l'operazione ha successo, il Worker acquisisce il lock esclusivo e procede all'inferenza VLM sull'HPC.
- Se un secondo pod Worker (generato dall'autoscaling) tenta di elaborare un'altra immagine parallelamente, fallirà l'acquisizione del lock. Aniché terminare con un errore, il pod entrerà in un ciclo di *wait* asincrono, riprovando l'acquisizione ogni 5 secondi, mettendo temporaneamente in pausa l'elaborazione del suo specifico task.
- Al termine del job HPC, il primo Worker rilascia la chiave (`DEL`), sbloccando istantaneamente il Worker in attesa.

Questo pattern architetturale, tipico delle infrastrutture *enterprise*, ha permesso di scindere le operazioni scalabili da quelle contingentate. Le fasi di download delle immagini, il preprocessing, l'inferenza di modelli Baseline (es. ResNet/CLIP) e la Vector Search vengono eseguite su decine di pod in parallelo puro; l'accesso alla GPU dell'HPC viene invece serializzato dinamicamente, garantendo tolleranza ai guasti e resilienza totale senza alcuno spreco di risorse Cloud.

3 Containerizzazione e Orchestrazione Locale

Una transizione efficace verso il paradigma Cloud-Native impone, come requisito fondamentale, l'indipendenza assoluta dell'applicativo dall'ambiente hardware e software sottostante. Al fine di scongiurare la nota problematica del "*it works on my machine*" e per garantire un deployment privo di attriti, il primo step implementativo è consistito in una rigorosa **containerizzazione** dell'intera suite applicativa.

Successivamente, prima di allocare risorse onerose su un Cloud pubblico, l'intera architettura distribuita è stata modellata e collaudata *on-premise* (in locale). A tal fine si è proceduto alla simulazione di un vero e proprio data-center virtuale all'interno di una singola workstation, utilizzando tecnologie di virtualizzazione leggere (Multipass) e di orchestrazione (K3s e Ansible).

3.1 La Containerizzazione con Docker

L'applicazione monolitica originale è stata destrutturata in tre microservizi logici primari, ciascuno isolato all'interno di una specifica immagine **Docker**:

- **Frontend Container:** Un'applicazione React (Vite) pacchettizzata insieme a un server NGINX ad alte prestazioni per il *serving* dei file statici. L'immagine Docker è stata costruita mediante un approccio *multi-stage build* per ridurre drasticamente il peso finale (scartando le dipendenze di Node.js e le directory 'node_modules' non necessarie in fase di runtime).
- **Backend Container:** Un server Python basato sul framework asincrono FastAPI. Questo container espone unicamente l'endpoint di caricamento (es. `/api/v1/search`), registra lo stato iniziale sul DB e innesca la produzione di messaggi verso il broker. Il container è *stateless* e non mantiene alcuno stato persistente in memoria.
- **AI Worker Container:** L'elemento più massiccio e complesso, contenente lo stack PyTorch, le librerie CUDA, torchvision, FAISS (per la similarità vettoriale) e le dipendenze di rete (Paramiko per SSH). Il Worker resta perennemente in ascolto in modalità *long-polling* sulla coda messaggi.

Oltre al codice *custom*, l'ambiente locale fa affidamento su container di terze parti per i servizi di persistenza e comunicazione, ovvero **PostgreSQL** (database relazionale per l'anagrafica dei task), **Redis** (in-memory store per la cache degli stati e i semafori) e **RabbitMQ** (Message Broker che funge da coda locale).

3.2 Simulazione di una Topologia Multi-Nodo tramite Multipass

Al fine di validare l'architettura Kubernetes prima del deploy su AWS EKS, si è deciso di ricreare un ambiente di orchestrazione multi-nodo in locale. Essendo impraticabile l'uso di cluster fisici, si è optato per l'impiego di **Multipass**, uno strumento sviluppato da Canonical che consente l'orchestrazione rapida di macchine virtuali Ubuntu su hypervisor nativi (KVM su Linux, Hyper-V su Windows, HyperKit su macOS).

Attraverso script di *provisioning* custom (`setup_multipass.sh`), sono state generate tre Macchine Virtuali logicamente separate:

1. **k8s-master:** Il nodo di Control Plane, incaricato di esporre le API Server di Kubernetes e prendere le decisioni di scheduling.
2. **k8s-worker1** e **k8s-worker2:** I nodi di elaborazione fisica, designati all'esecuzione effettiva dei container (Pod).

Questa compartimentazione ha permesso di collaudare le dinamiche di rete interna del cluster, le *network policies* e lo scheduling multi-nodo, mettendo alla prova la robustezza del sistema di fronte alla caduta intenzionale di uno dei nodi Worker.

3.3 Automazione del Cluster con K3s e Ansible

Per trasformare le macchine virtuali "nude" in un cluster Kubernetes pienamente operativo, l'installazione manuale (via `kubeadm`) è stata scartata a favore di una soluzione automatizzata e ripetibile. Si è scelto **K3s**, una distribuzione di Kubernetes certificata e alleggerita,

ottimizzata nativamente da Rancher Labs eliminando *driver* legacy (in-tree cloud providers) e sostituendo etcd con un più leggero database SQLite o MySQL-based.

Per evitare qualsiasi interazione manuale, il processo di bootstrap è stato codificato in un *playbook* **Ansible**. L'architettura IaC (Infrastructure as Code) basata su Ansible ha permesso di:

- Aggiornare e mettere in sicurezza i pacchetti di sistema operativo (OS hardening) su tutte le VM in parallelo.
- Installare e configurare le chiavi SSH e le regole di firewall (**ufw**) necessarie alla comunicazione intra-cluster.
- Eseguire in modo asincrono lo script di installazione del Master node, estrapolarne il token crittografico generato, per poi iniettarlo in maniera dinamica nei Worker node per avviare il processo di "join" al cluster.

Al termine dell'esecuzione del *playbook* Ansible, l'ambiente di sviluppo restituisce in automatico il file **kubeconfig** completo, fornendo agli operatori un cluster Kubernetes multi-nodo *on-premise* funzionante, effimero e distruttibile con un solo comando, gettando le fondamenta perfette per il successivo collaudo del codice di *cloud deployment*.

4 Infrastruttura AWS e Servizi Gestiti

Il completamento della fase di test *on-premise* ha fornito le garanzie logiche necessarie per procedere al deployment in un ambiente di produzione reale. La piattaforma scelta per ospitare l'applicativo è Amazon Web Services (AWS), il provider cloud leader di mercato. L'obiettivo primario di questa transizione è stato duplice: da un lato, delegare la gestione dei servizi critici (database e code) a soluzioni PaaS/SaaS native per massimizzarne l'affidabilità; dall'altro, istanziare un cluster Kubernetes in grado di scalare dinamicamente le risorse di calcolo.

4.1 Infrastructure as Code con Terraform

La creazione dell'infrastruttura AWS non è stata eseguita manualmente tramite la console web, procedura notoriamente soggetta a errori umani e difficilmente riproducibile. Si è invece adottato un rigoroso approccio *Infrastructure as Code* (IaC) impiegando **HashiCorp Terraform**.

Tramite script dichiarativi (codificati in HCL - HashiCorp Configuration Language), l'intera topologia cloud è stata modellata come codice versionabile. Questo ha garantito la totale idempotenza del deployment: l'infrastruttura può essere distrutta e ricreata in modo identico in pochi minuti, assicurando una coerenza perfetta tra l'ambiente di *staging* e quello di *production*.

4.2 Topologia di Rete e Sicurezza (VPC)

Il livello base dell'architettura AWS è costituito da una **Virtual Private Cloud (VPC)**, un perimetro di rete logicamente isolato e dedicato in modo esclusivo al progetto. Per garantire alti standard di sicurezza (*Security by Design*), lo spazio di indirizzamento IP (CIDR) della VPC è stato rigorosamente segmentato in due livelli di *subnet*:

- **Subnet Pubbliche:** Esposte direttamente a Internet tramite un *Internet Gateway* (IGW). Queste reti ospitano esclusivamente il bilanciatore di carico (*Application Load Balancer* - ALB) e un *NAT Gateway*. Nessun nodo di calcolo o database risiede in questa porzione di rete.
- **Subnet Private:** Completamente isolate dal traffico in ingresso proveniente da Internet. All'interno di queste subnet sicure sono stati istanziati i nodi del cluster Kubernetes (EKS) e i database relazionali e NoSQL. I pod ospitati in queste subnet ottengono l'accesso a Internet in uscita (es. per scaricare i modelli AI esterni) in maniera unidirezionale passando attraverso il NAT Gateway posizionato nella subnet pubblica.

Questa topologia, unita a ferree regole di *Security Group* che limitano il traffico intra-subnet solo alle porte strettamente necessarie (es. porta 5432 per Postgres, 6379 per Redis), rende i componenti critici invulnerabili a tentativi di accesso diretto dall'esterno.

4.3 Offloading verso Servizi Gestiti AWS (PaaS/SaaS)

Nell'ecosistema cloud-native, gestire in proprio (su macchine virtuali EC2) infrastrutture come database o message broker è considerata una pratica sconsigliata (*anti-pattern*), a causa dell'ingente carico operativo richiesto per la manutenzione, il patching e i backup. Pertanto, i servizi precedentemente virtualizzati in locale sono stati migrati verso le controparti completamente gestite di AWS:

- **Amazon S3 (Storage Distribuito):** Ha sostituito il file system locale per l'archiviazione delle immagini. S3 offre durabilità estrema (99.999999999%) e decupla il traffico statico dai web server.
- **Amazon RDS for PostgreSQL:** Ha sostituito il container Postgres locale. RDS fornisce backup automatici, crittografia a riposo (*at-rest*) e manutenzione automatica del motore di database, ospitando la tabella anagrafica dei task.
- **Amazon ElastiCache (Redis):** Ha sostituito l'istanza Redis locale. Svolge la triplice funzione di cache ultraveloce per lo stato dei job (interrogata dal Frontend), di backend per Celery/memoria temporanea, e soprattutto di **Distributed Lock** per serializzare l'accesso all'HPC universitario, come discusso nella Sezione 2.
- **Amazon SQS (Simple Queue Service):** Ha sostituito RabbitMQ. Essendo un servizio *serverless*, SQS elimina la necessità di gestire cluster di code e dimensiona automaticamente il proprio *throughput* in base al traffico, fornendo code FIFO o Standard per lo smistamento dei job AI verso i Worker.

4.4 Risoluzione Criticità Hardware: Out-Of-Memory (OOM)

Durante i test di messa in produzione, è emersa una grave criticità hardware legata al caricamento in memoria della galleria dei grafi di scena: il file tensoriale grezzo (`test_gallery_scene_graphs.pt`) ha una dimensione di oltre 1.1 GB. Il caricamento diretto in RAM tramite le primitive di PyTorch richiedeva l’allocazione di oltre 3 GB di memoria scompattata. Questo portava sistematicamente in *Out-Of-Memory* (OOM) le istanze EC2 di classe `t3.small` (limitate a 2 GB di RAM) in uso per i nodi del cluster, causando crash irreversibili (errori HTTP 502 Bad Gateway).

Un iniziale tentativo di *vertical scaling*, puntando a istanze `t3.medium` (4 GB di RAM), è stato precluso dalle restrizioni di budget e policy imposte dall’account *AWS Free Tier* (l’API cloud restituiva un `FreeTierRestrictionError`).

La soluzione architetturale definitiva ha perciò previsto la rimozione del caricamento dei tensori dai pod applicativi. Al suo posto, si è optato per una strategia di pre-calcolo (tramite un job locale) in cui l’intero dataset viene esportato in migliaia di leggeri file JSON, uno per ogni scena. Questi file sono stati sincronizzati direttamente su **Amazon S3**. Il backend è stato riprogrammato per interrogare il bucket S3 al volo (tramite protocollo HTTP/S3) recuperando la topologia del grafo richiesto on-demand. Questa modifica ha abbattuto drasticamente il *footprint* di memoria dei container, garantendo la totale stabilità dell’applicativo anche sulle macchine modeste fornite dal tier gratuito.

4.5 Innesco Serverless (Event-Driven) tramite AWS Lambda

Un ulteriore passo verso la decentralizzazione asincrona è stato raggiunto integrando **AWS Lambda**. Invece di affidare al Backend il compito di ricevere l’immagine e salvarla, il flusso è stato modificato in modo tale che il Frontend carichi l’immagine direttamente su un bucket S3.

Il caricamento del file (evento `s3:ObjectCreated`) innesca in modo invisibile, reattivo e *serverless* una funzione AWS Lambda. Quest’ultima estrae i metadati, inietta un nuovo messaggio nella coda SQS e termina la sua esecuzione in pochi millisecondi. Questa architettura ad eventi riduce ulteriormente le responsabilità del Backend FastAPI, garantendo un *decoupling* applicativo assoluto.

5 Deployment su EKS ed Auto-Scaling Elastico

Una volta consolidata l’infrastruttura sottostante su AWS, l’ultimo tassello dell’architettura ha riguardato il *deployment* effettivo dei microservizi all’interno dell’Elastic Kubernetes Service (EKS) e la configurazione delle logiche di scalabilità automatica, essenziali per far fronte a carichi di lavoro variabili tipici delle applicazioni cloud-native.

5.1 Gestione dei Secret e Manifesti Kubernetes

Il deployment applicativo è stato dichiarato tramite manifesti YAML standard di Kubernetes (*Deployment*, *Service*, *Ingress*). Particolare attenzione è stata rivolta alla sicurezza e all'isolamento delle credenziali. Parametri sensibili quali le stringhe di connessione a RDS e Redis, i token di accesso alle API AWS e, in particolar modo, le chiavi private SSH necessarie al Worker per autenticarsi sul cluster HPC, non sono mai stati inseriti in chiaro nel codice sorgente. Sono stati invece iniettati dinamicamente all'interno di oggetti **Secret** di Kubernetes, montati a runtime come variabili d'ambiente o come volumi cifrati (*tmpfs*) all'interno dei container.

Il traffico HTTP in ingresso è stato esposto su Internet tramite un *Ingress Controller*, il quale è stato automaticamente associato da AWS a un Application Load Balancer (ALB) pubblico, posizionato nella *Subnet Pubblica* della VPC per smistare il traffico sui pod del Frontend e del Backend situati nelle *Subnet Private*.

5.2 Event-Driven Auto-Scaling con KEDA

La gestione delle risorse computazionali per i workload di intelligenza artificiale pone una sfida unica: l'elaborazione di un'immagine può consumare tempi e risorse imponenti. L'approccio classico di Kubernetes all'autoscaling, l'*Horizontal Pod Autoscaler* (HPA), si basa principalmente su metriche hardware (percentuale di CPU o RAM utilizzata). Tuttavia, nel nostro scenario asincrono, un picco di traffico si traduce in un improvviso accumulo di messaggi nella coda SQS, non in un aumento istantaneo della CPU del Worker (il quale può processare un solo messaggio alla volta).

Per risolvere questo disallineamento, si è abbandonato l'HPA standard in favore di **KEDA** (*Kubernetes Event-Driven Autoscaling*). KEDA è in grado di agire da ponte tra Kubernetes e i provider cloud, interrogando direttamente le metriche dei Message Broker esterni.

Nello specifico, è stato configurato un `ScaledObject` che istruisce Kubernetes a monitorare la coda Amazon SQS. Il parametro cruciale per il tuning di questa operazione è stato il `queueLength`. Impostando questo valore a 1, si è comunicato al cluster una regola aggressiva ed elastica: per ogni singolo messaggio presente in coda, KEDA deve effettuare lo **scale-out** (generare) di un nuovo pod Worker, fino a un massimo preimpostato (*maxReplicaCount*).

In assenza di messaggi (coda vuota), KEDA scala il Deployment a **zero repliche** (*scale-to-zero*), abbattendo completamente i costi infrastrutturali nei periodi di inattività, realizzando così il vero potenziale del paradigma Serverless applicato ai container.

L'interazione tra KEDA e il *Distributed Lock* su Redis (discusso nel Capitolo 2) rappresenta l'apice ingegneristico di questo sistema: l'architettura è libera di scalare orizzontalmente in modo massiccio per aggredire una coda SQS piena di immagini da processare in parallelo, delegando simultaneamente la sincronizzazione fine e la serializzazione delle risorse GPU al semaforo logico gestito in-memory.

A titolo dimostrativo, si riporta in Figura 1 un log reale del cluster registrato durante un test di stress, in cui l’HPA governato da KEDA effettua uno scale-out reattivo portando le repliche dei worker applicativi da 1 a 3 a causa di un improvviso accumulo di task sulla coda SQS.

```
$ kubectl get hpa -n default
```

NAME	REFERENCE	TARGETS	MINPODS	MAXPODS	REPLICAS
keda-hpa-worker-sqs-scaler	Deployment/worker	667m/1 (avg)	1	10	3


```
$ kubectl get pods -n default
```

NAME	READY	STATUS	AGE	
worker-7d85889bf5-7w4cn	1/1	Running	16m	
worker-7d85889bf5-47vsr	1/1	Running	77s	<-- (Nuovo pod scalato da KEDA)
worker-7d85889bf5-njzfh	1/1	Running	62s	<-- (Nuovo pod scalato da KEDA)

Figura 1: Esempio di Autoscaling dinamico Event-Driven registrato live dal cluster Kubernetes.

5.3 Continuous Integration e Continuous Deployment (CI/CD)

A coronamento del ciclo di vita del software, è stata implementata una pipeline di automazione basata su **GitHub Actions**. Qualsiasi modifica al codice sorgente spinta (tramite *git push*) sul branch principale innesca automaticamente un flusso di lavoro diviso in due macro-fasi:

- **Build & Publish:** L’infrastruttura GitHub compila le nuove immagini Docker per i microservizi aggiornati, iniettando le dipendenze fresche, e le deposita in un Container Registry sicuro (GHCR).
- **Rolling Update:** La pipeline si connette in modo autenticato al cluster EKS su AWS, aggiornando l’hash dell’immagine nei Deployment Kubernetes. Kubernetes avvia quindi un *Rolling Update*, spegnendo i vecchi pod e accendendo quelli nuovi in maniera graduale, garantendo uno *Zero-Downtime Deployment* e assicurando che l’utente finale non percepisca alcuna interruzione del servizio durante gli aggiornamenti.

Questo approccio GitOps chiude il cerchio dell’infrastruttura Cloud-Native, fornendo un sistema robusto, osservabile, elastico e completamente automatizzato, in grado di portare modelli AI accademici e pesanti in un ambiente di produzione scalabile.

6 Conclusioni e Sviluppi Futuri

L’ingegnerizzazione di un sistema di *Scene Understanding* e retrieval semantico distribuito ha evidenziato in maniera chiara il potenziale, ma anche l’incredibile complessità, dello sviluppo Cloud-Native moderno. Il progetto, nato inizialmente come script locale fortemente limitato e sincrono, è stato frammentato ed elevato a un’infrastruttura Enterprise pronta alla produzione.

Il raggiungimento dei tre milestone ha portato a risultati concreti:

- **Decoupling Perfetto:** L’adozione del pattern asincrono tramite broker di messaggistica ha salvato il frontend web dal collasso sotto carichi pesanti, fornendo al contempo feedback intermedi all’utente finale.

- **Gestione del Codice Universale:** Sfruttando Terraform e Ansible, si è dimostrato come l'intero strato infrastrutturale possa essere documentato, versionato su Git e riprodotto ciecamente in una manciata di minuti, annullando il rischio di derivazioni configurazionali o errori manuali (Configuration Drift).
- **Ottimizzazione Finanziaria (FinOps):** Scontrandosi attivamente con i limiti fisici imposti dal Free Tier di AWS (istanze `t3.micro`), il progetto è riuscito a eseguire modelli complessi adattando l'architettura all'uso di **K3s**. La rinuncia a un cluster Kubernetes standard ha confermato come la flessibilità architetturale sia vitale per contenere i costi computazionali.

6.1 Sviluppi Futuri

Nonostante il sistema sia stabile e testato, l'architettura attuale pone le basi per futuri sviluppi e raffinamenti, in particolare in ottica di estrema scalabilità:

1. **Autoscaling Dinamico basato su Code (KEDA):** Attualmente il numero di pod Worker è fisso. Integrando *Kubernetes Event-driven Autoscaling* (KEDA), il cluster potrebbe scalare dinamicamente (da 0 a N) i container Worker basandosi sulla reale lunghezza della coda SQS, spegnendo completamente i processi computazionali nei momenti di inattività.
2. **Accelerazione Hardware (GPU Node):** Data l'intensità matematica delle Graph Neural Network e dei modelli multimodali Qwen2.5, una futura migrazione verso nodi EC2 appartenenti alla famiglia `g4dn` (provvisi di GPU NVIDIA T4) ridurrebbe il tempo di inferenza per singola immagine da diversi secondi a frazioni minime.
3. **Osservabilità Totale (Prometheus e Grafana):** L'implementazione di uno strato di monitoraggio avanzato permetterebbe di profilare in tempo reale il consumo di memoria dei singoli pod e i tempi di attraversamento della pipeline SQS, facilitando l'individuazione di ulteriori colli di bottiglia e allarmi proattivi per il team DevOps.

In definitiva, questo elaborato dimostra come la transizione da codice di ricerca accademico (modelli Deep Learning sperimentali) a prodotto software as-a-Service solido e commerciale passi inevitabilmente attraverso rigorose best practice di Ingegneria del Software, Orchestrazione Container e Cloud Computing.

Riferimenti bibliografici